

# 06026212 DATA WAREHOUSING

(การสร้างคลังข้อมูล)

## 4 - Star Schema Design

หัวข้อ: Star Schema Design (Surrogate Key & Degenerate Dimension)

ผู้สอน: อ.เฉลิมพล ศิริกายน

ภาคเรียนที่ 1 ปีการศึกษา 2569

# วัตถุประสงค์การเรียนรู้

- อธิบายโครงสร้างของ Star Schema ได้อย่างถูกต้อง
- เข้าใจและวิเคราะห์ความสัมพันธ์ระหว่าง KPI กับ Granularity เพื่อกำหนดโครงสร้างของ Fact Table ได้
- จำแนกประเภทของ KPI และอธิบายผลต่อการออกแบบ Fact Table
- อธิบายแนวคิดและเหตุผลในการใช้ Surrogate Key แทน Natural Key
- แยกแยะ Degenerate Dimension จาก Dimension ปกติได้ และรู้ว่าเมื่อไรควรใช้


OLTP

VS

OLAP




# Data Warehouse Modeling






***Star Schema***



***Snowflake Schema***

# Star Schema



# KPI + Granularity = Fact Table

- **KPI**

- **Key Performance Indicator**

- คือสิ่งที่ธุรกิจใช้วัดความสำเร็จ เช่น ยอดขาย, จำนวนสินค้าที่ขาย, จำนวนแท้มที่ใช้

- **Granularity**

- ความละเอียดของข้อมูล เช่น:
  - 1 แถว = 1 รายการสินค้าในใบเสร็จ
  - 1 แถว = 1 ยอดขายต่อวันต่อพนักงาน

# ตัวอย่าง: KPI + Granularity = Fact Table

- KPI: ยอดขาย, จำนวนชิ้น, แต้มที่ใช้
- Granularity: 1 แถว = 1 รายการสินค้าใน 1 ใบเสร็จ
- Fact Table: sales\_fact (revenue, quantity, points\_redeemed, ...)



KPI ของโรงพยาบาล

# ประเภทของ KPI

มุมมองของ DW แบ่งเป็น 3 แบบ:

- Transactional KPI
- Aggregated KPI
- Derived KPI

# Transactional KPI (Event-based)

| ลักษณะ                   | เกิดจากเหตุการณ์แต่ละรายการ (transaction)                                                                           |
|--------------------------|---------------------------------------------------------------------------------------------------------------------|
| เก็บใน Fact Table ได้ตรง | ✅ ใช้ sales_fact รองรับได้โดยตรง                                                                                    |
| ต้องการ Granularity สูง  | เช่น ต่อรายการ                                                                                                      |
| ตัวอย่าง KPI             | <ul style="list-style-type: none"><li>- จำนวนชิ้นที่ขาย</li><li>- ยอดขายต่อรายการ</li><li>- แต้มที่ใช้แลก</li></ul> |

## Aggregated KPI (Summary-based)

| ลักษณะ                      | ต้องคำนวณจากหลายรายการ (summary, group by)                                                                                         |
|-----------------------------|------------------------------------------------------------------------------------------------------------------------------------|
| เก็บใน Fact Table ได้โดยตรง |  ไม่ควร                                          |
| ทำจากการ Aggregate          |  ต้องสร้าง View หรือ Summary Table เพิ่ม         |
| ตัวอย่าง KPI                | <ul style="list-style-type: none"><li>- ยอดขายรวมต่อเดือน</li><li>- ยอดขายเฉลี่ยต่อพนักงาน</li><li>- Top 5 สินค้ายอดนิยม</li></ul> |

## Derived KPI (Calculated/Ranked)

| ลักษณะ                                  | คำนวณจากหลาย KPI หรือใช้ฟังก์ชันพิเศษ                                                                                                                                 |
|-----------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| เก็บใน Fact Table                       |  ไม่ควร                                                                            |
| ต้องใช้ Logic<br>เช่น Ranking, Ratio, % |  ควรคำนวณใน Layer หลัง<br>(BI / Analytical SQL / Python)                           |
| ตัวอย่าง KPI                            | <ul style="list-style-type: none"><li>- Margin (%) = Revenue</li><li>- Cost / Revenue</li><li>- อันดับสินค้ายอดนิยมต่อพนักงาน</li><li>- % ใช้โปรโมชั่นในบิล</li></ul> |

# สรุปประเภทของ KPI

| ประเภท KPI    | เก็บใน Fact ได้?                                                                  | ตัวอย่าง              | ใช้ทำอะไร          |
|---------------|-----------------------------------------------------------------------------------|-----------------------|--------------------|
| Transactional |  | quantity, revenue     | เก็บ transaction   |
| Aggregated    |  | total sales per store | สร้าง Summary View |
| Derived       |  | top product, margin   | ใช้ใน Dashboard    |

Fact Table เก็บเหตุการณ์ (Event)  
ไม่ได้เก็บ “คำตอบ” หรือ “Insight” โดยตรง

# จุดเด่นของ Star Schema

- มีโครงสร้างไม่ซับซ้อน เข้าใจได้ง่าย
- Query เร็ว (ไม่ต้อง Join ซ้อนหลายระดับ)
- เหมาะกับ BI Tools เช่น Power BI, Tableau, Metabase
- ประเด็นที่ต้องพิจารณา => **KEY**

# Surrogate Key

- คีย์เทียม หรือรหัสตัวแทน (เป็นตัวเลข)
- สร้างใหม่โดยอัตโนมัติในกระบวนการ ETL
- ใช้เป็น Primary Key ของ Dimension Table

# ทำไมต้องใช้ Surrogate Key?

| ปัญหา                               | ทางแก้ด้วย Surrogate Key                  |
|-------------------------------------|-------------------------------------------|
| ระบบต้นทางเปลี่ยนรหัส               | ใช้ Surrogate Key เดิม                    |
| รหัสจากระบบต่างกัน (หลายแหล่ง)      | ใช้ Surrogate Key กลาง                    |
| ข้อมูลเปลี่ยนตามเวลา (Time Variant) | ใช้คนละ Surrogate Key แม้จะเป็นลูกค้าเดิม |
| รหัสซ้ำกันในระบบเดิม                | แยกด้วย Surrogate Key ได้                 |
| Performance ใน Join                 | Join ด้วย INT key เร็วกว่า String         |

# Natural Key vs Surrogate Key

## Natural Key

## Surrogate Key

| customer_code | customer_name | customer_key |
|---------------|---------------|--------------|
| CUST-998      | สุชาติ        | 100001       |
| C998          | สุชาติ        | 100001       |

# ตัวอย่าง: Surrogate Key

- ระบบต้นทาง (CRM):

| customer_code | customer_name | city       | effective_date |
|---------------|---------------|------------|----------------|
| C10234        | Somchai Co.   | Bangkok    | 2019-01-01     |
| C10234        | Somchai Co.   | Chiang Mai | 2022-04-02     |
| C88210        | Preeya Ltd.   | Bangkok    | 2019-01-01     |

- Dimension & Fact Table:

| customer_key | customer_code | name        | city       | start_date | end_date   |
|--------------|---------------|-------------|------------|------------|------------|
| 1001         | C10234        | Somchai Co. | Bangkok    | 2019-01-01 | 2022-04-01 |
| 1002         | C10234        | Somchai Co. | Chiang Mai | 2022-04-02 | NULL       |
| 1003         | C88210        | Preeya Ltd. | Bangkok    | 2019-01-01 | NULL       |

| fact_id | customer_key | revenue |
|---------|--------------|---------|
| 1       | 1001         | 1200.00 |
| 2       | 1002         | 900.00  |
| 3       | 1003         | 1000.00 |

# การสร้าง Surrogate Key

- ใช้ Sequence หรือ Auto-Increment (ใน RDBMS เช่น PostgreSQL, MySQL)
- ใช้ UUID ถ้าต้องการความ unique ระดับ global
- ใช้ ETL Tool สร้างก่อนโหลด เช่น Airbyte, Apache NiFi, Talend, dbt

# Degenerate Dimension

FLOWACCOUNT

บริษัท โฟลว์แอคเคาท์ ทดสอบ จำกัด (สำนักงานใหญ่)  
141/12 ชั้น 11 บุนนิต 12B อาคารชุด สฤลไทย สุรวงศ์ ทาวเวอร์ ถนนสุรวงศ์  
แขวงสุริยวงศ์ เขตบางรัก กรุงเทพมหานคร 1050  
เลขประจำตัวผู้เสียภาษี 0105558096348  
โทร. 020268989

ลูกค้า  
บริษัท ตัวอย่าง จำกัด (สำนักงานใหญ่) (สำนักงานใหญ่ 00000)  
141/12 ชั้น 11 บุนนิต 12B อาคารชุด สฤลไทย สุรวงศ์ ทาวเวอร์  
ถนนสุรวงศ์ แขวงสุริยวงศ์ เขตบางรัก กรุงเทพมหานคร 10500 00000  
เลขประจำตัวผู้เสียภาษี 0105558096348

ใบกำกับภาษี/ใบเสร็จรับเงิน

ต้นฉบับ (เอกสารออกเป็นชุด)

เลขที่

วันที่

เครดิต

ครบกำหนด

ผู้ขาย

อ้างอิง

INV2025020003

27/02/2025

30 วัน

29/03/2025

โอบอลส์ ยอดเยี่ยม

BL2025020001

ชื่องาน

ผู้ติดต่อ

เบอร์โทร

อีเมล

เมืกกาแพคค์ 500 ถุง

คุณตัวอย่าง

099-999-9999

email@email.com

| # | รายละเอียด          | จำนวน | ราคาต่อหน่วย | ส่วนลด | มูลค่า    |
|---|---------------------|-------|--------------|--------|-----------|
| 1 | เมืกกาแพคค์ 500 ถุง | 50    | 250.00       | 5 %    | 11,875.00 |

รวมเป็นเงิน

12,500.00 บาท

ส่วนลด

625.00 บาท

จำนวนเงินหลังหักส่วนลด

11,875.00 บาท

ภาษีมูลค่าเพิ่ม 7%

776.87 บาท

ราคาไม่รวมภาษีมูลค่าเพิ่ม

11,098.13 บาท

จำนวนเงินรวมทั้งสิ้น

11,875.00 บาท

(หนึ่งหมื่นหนึ่งพันแปดร้อยเจ็ดสิบบาทถ้วน)

- ข้อมูลที่มีความจำเป็นต้องเก็บไว้
- ไม่จัดอยู่ในชุดข้อมูลของ Dimension ใด ๆ
- ไม่มีการ share หรือ reuse ในแถวอื่น
- เป็นมิติที่ ไม่จำเป็น ต้องแยกเป็นตาราง
- เป็น 'Dimension Attribute' ที่ถูกเก็บอยู่ใน Fact Table โดยตรง

## ตัวอย่าง: Degenerate Dimension


| sale_id | customer_key | product_key | sale_date_key | invoice_number | quantity | revenue |
|---------|--------------|-------------|---------------|----------------|----------|---------|
| 10001   | 101          | 201         | 20240722      | INV-001        | 2        | 500     |
| 10002   | 101          | 202         | 20240722      | INV-001        | 1        | 250     |
| 10003   | 102          | 203         | 20240723      | INV-002        | 3        | 750     |

# ข้อควรระวังในการใช้ Degenerate Dimension

- ไม่สามารถแบ่งไปอยู่ใน Dimension Table ใดได้เลย
- ไม่ซ้ำกับใคร (เช่น หมายเลขเอกสารที่ไม่ซ้ำกัน)
- มีความสำคัญต่อการวิเคราะห์ระดับเอกสารหรือเหตุการณ์


# ตัวอย่าง: Star Schema (Sales Data Model)

track sales metrics, such as revenue, quantity sold, and profit



# ตัวอย่าง: Star Schema (Financial Data Model)


track financial metrics, such as revenue, expenses, and profit



ภาพจาก [What Is the Star Schema Data Model? An Explanation with 3 Examples](#)

# ตัวอย่าง: Star Schema (Human Resources (HR) Data Model)

track employee metrics, such as employee turnover, training, and performance



# กรณีศึกษา: Coffee Club

## ระบบข้อมูลการขายสำหรับร้านกาแฟระบบสมาชิก

- บริบทธุรกิจ (Business Context)

Coffee Club เป็นร้านกาแฟที่มีหลายสาขาทั่วประเทศไทย โดยมีระบบสมาชิกสะสมแต้ม ระบบโปรโมชั่นตามฤดูกาล และระบบพนักงานประจำสาขา การขายเกิดขึ้นได้แบบปกติ และแบบเข้าร่วมการจัดโปรโมชั่น โดยแต่ละการขายจะบันทึกข้อมูลลูกค้า สินค้า พนักงานที่ให้บริการ โปรโมชั่นที่ใช้ (ถ้ามี) และแต้มที่แลก

ข้อมูลถูกเก็บในรูปแบบแฟลตไฟล์ (CSV) ซึ่งประกอบด้วยข้อมูลทุกอย่างในแถวเดียว แต่บริษัทมีแผนจะนำข้อมูลเหล่านี้มาโหลดเข้าสู่ระบบ Data Warehouse เพื่อใช้สำหรับการวิเคราะห์ยอดขาย ประสิทธิภาพของโปรโมชั่น และพฤติกรรมลูกค้า

# โครงสร้างข้อมูลใน CSV (Data Dictionary) - 1

| Column name    | Description                                     |
|----------------|-------------------------------------------------|
| sale_id        | รหัสประจำธุรกรรมการขายแต่ละรายการ (Primary Key) |
| invoice_number | หมายเลขใบเสร็จที่ใช้ในธุรกรรม                   |
| sale_date      | วันที่ที่มีการขายสินค้าเกิดขึ้น                 |
| customer_code  | รหัสลูกค้าที่ได้จากระบบต้นทาง                   |
| customer_name  | ชื่อลูกค้า (ชื่อจริง)                           |
| gender         | เพศของลูกค้า (M = ชาย, F = หญิง)                |
| birth_year     | ปีเกิดของลูกค้า                                 |
| product_code   | รหัสประจำสินค้าที่ขาย                           |

# โครงสร้างข้อมูลใน CSV (Data Dictionary) - 2

| Column name  | Description                                                                                                 |
|--------------|-------------------------------------------------------------------------------------------------------------|
| product_name | ชื่อสินค้าที่ขาย                                                                                            |
| category     | ประเภทของสินค้า (เช่น กาแฟ ชา เบเกอรี่)                                                                     |
| size         | ขนาดของสินค้า (S, M, L หรือ '-')                                                                            |
| unit_price   | ราคาต่อหน่วยของสินค้า                                                                                       |
| quantity     | จำนวนสินค้าที่ขายในรายการนี้                                                                                |
| revenue      | จำนวนเงินที่ลูกค้าชำระจริงหลังหักส่วนลดแล้ว ( $\text{unit\_price} \times \text{quantity} - \text{ส่วนลด}$ ) |
| store_code   | รหัสร้านค้าที่ขายสินค้า                                                                                     |
| store_name   | ชื่อของร้านค้า                                                                                              |

# โครงสร้างข้อมูลใน CSV (Data Dictionary) - 3

| Column name     | Description                               |
|-----------------|-------------------------------------------|
| province        | จังหวัดที่ตั้งของร้านค้า                  |
| staff_code      | รหัสพนักงานที่ดูแลการขาย                  |
| staff_name      | ชื่อของพนักงาน                            |
| position        | ตำแหน่งของพนักงาน (เช่น Barista, Cashier) |
| promo_code      | รหัสโปรโมชั่นที่ใช้ (ถ้ามี)               |
| promo_desc      | คำอธิบายของโปรโมชั่นที่ใช้                |
| points_redeemed | จำนวนแต้มสะสมที่ลูกค้าใช้แลกในรายการนี้   |

# Business Processes ที่เกี่ยวข้อง

| Business Process | รายละเอียด                                  |
|------------------|---------------------------------------------|
| Make a Sale      | ลูกค้าซื้อสินค้าในร้าน สะสมแต้ม หรือแลกแต้ม |
| Apply Promotion  | ใช้โปรโมชั่นลดราคา ณ จุดขาย                 |
| Serve by Staff   | พนักงานบริการลูกค้าแต่ละคนในแต่ละบิล        |

# KPI ที่ต้องการ

| Business Process | KPI                                                                                                                                                                  |
|------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Make a Sale      | <ul style="list-style-type: none"><li>- ยอดขายรวม (revenue)</li><li>- ยอดขายต่อบิล (รวมจาก invoice_number)</li><li>- ยอดขายต่อสินค้า</li></ul>                       |
| Apply Promotion  | <ul style="list-style-type: none"><li>- มูลค่าการใช้โปรโมชั่น (แยกตาม promo_code)</li><li>- จำนวนบิลที่ใช้โปรโมชั่น</li><li>- แท้มที่แลกใช้ (แยกตามลูกค้า)</li></ul> |
| Serve by Staff   | <ul style="list-style-type: none"><li>- ยอดขายต่อพนักงาน (staff_code)</li><li>- ประเภทสินค้าที่ขายมากที่สุดโดยพนักงานแต่ละคน</li></ul>                               |

# Workshop

- ให้อวิเคราะห์ข้อมูลของ Coffee Club เพื่อออกแบบ Star Schema ที่สอดคล้องกับ KPI ที่ต้องการ
- เขียน ER-Diagram เพื่อแสดง Star Schema ที่ได้
- ใช้ bdt เพื่อแปลงข้อมูลให้เป็นไปตามโครงสร้างของ Star Schema