

Lab Sheet: 06026212 DATA WAREHOUSING

(การสร้างคลังข้อมูล)

สัปดาห์ที่ 9: ETL (Incremental Load + SCD Type 2) ด้วย dbt

ระยะเวลา: 2 ชั่วโมง

วัตถุประสงค์

- สร้าง dbt project ใหม่ชื่อ lab9 และฐานข้อมูล lab9_dw ได้
- สร้าง Snowflake Schema ทั้งหมดจากไฟล์ CSV ด้วย dbt
- โหลดข้อมูลขายแบบ incremental 2 batch โดยไม่เกิด fact ซ้ำ
- จัดการ dim_customer แบบ SCD Type 2 ด้วย dbt snapshot
- ตรวจสอบผลด้วย dbt test, dbt show และ dbt docs

เครื่องมือและชุดข้อมูล

รายการ	ใช้ทำอะไร
Docker Compose	เปิด postgres, dbt และ metabase จาก DWH_Lab(3).zip
coffee_sales_scd_new.csv	ข้อมูลยอดขาย 80 แถว ระหว่าง 2031-04-01 ถึง 2031-04-30
province_region_mapping_v2.csv	mapping จังหวัด-ภูมิภาค เพื่อสร้าง Snowflake geography

สถานการณ์ข้อมูล

แบ่งข้อมูลขายออกเป็น 2 batch ตาม sale_date: Batch 1 ก่อน 2031-04-15 จำนวน 40 แถว และ Batch 2 ตั้งแต่ 2031-04-15 จำนวน 40 แถว ข้อมูลจริงมี CUST-1007 เปลี่ยนชื่อจาก Arthit เป็น Tawon ใน Batch 2 จึงใช้สาคิด SCD Type 2 ได้โดยไม่ต้องสร้างข้อมูลจำลอง

1. สร้างฐานข้อมูลและ project ใหม่

เปิดบริการ จากนั้นสร้าง database lab9_dw ด้วย pgAdmin Query Tool

```
CREATE DATABASE lab9;
```

สร้างโครงสร้าง project และคัดลอกทั้งสอง dataset เข้า project

```
# Linux
mkdir -p dbt/lab9/{models/staging,models/intermediate,models/marts,snapshots,seeds}
```

```
# PowerShell
New-Item -ItemType Directory -Path "dbt/lab9/models/staging", "dbt/lab9/models/intermediate",
"dbt/lab9/models/marts", "dbt/lab9/snapshots", "dbt/lab9/seeds" -Force
```

1.1 กำหนด profile

ใน dbt_root/profiles.yml สร้าง profile ชื่อ lab9

```
lab9:
  target: dev
  outputs:
    dev:
      type: postgres
      host: postgres
      user: dw_user
      password: dw_pass
      port: 5432
      dbname: lab9
      schema: dbt
      threads: 4
```

1.2 สร้าง dbt_project.yml

```
name: 'lab9'
version: '1.0.0'
config-version: 2
profile: 'lab9'

model-paths: ['models']
seed-paths: ['seeds']
snapshot-paths: ['snapshots']

models:
  lab9:
    staging: {+materialized: view, +schema: staging}
    intermediate: {+materialized: view, +schema: intermediate}
    marts: {+schema: marts}

snapshots:
  lab9:
    +target_schema: snapshots
```

```
docker compose exec dbt sh -lc 'cd /usr/app/dbt/lab9 && dbt debug'
```

2. โหลด seeds และสร้าง staging layer

models/staging/stg_coffee_sales.sql

```
with source as (select * from {{ ref('coffee_sales_scd_new') }})
select
  sale_id::bigint as sale_id, invoice_number, sale_date::date as sale_date,
  customer_code, customer_name, gender, birth_year::int as birth_year,
  province, product_code, product_name, category, size,
  unit_price::numeric(12,2) as unit_price, quantity::int as quantity,
  revenue::numeric(18,2) as revenue,
  store_code, store_name, staff_code, staff_name, position,
```

```

nullif(promo_code,'') as promo_code,
nullif(promo_desc,'') as promo_desc,
coalesce(points_redeemed,0)::int as points_redeemed
from source

```

models/staging/stg_province_region.sql

```

select province_name, region_name
from {{ ref('province_region_mapping_v2') }}

```

```

docker exec -it dw_dbt bash
cd lab9
dbt seed --full-refresh
dbt run --select staging

```

หมายเหตุ: หลัง dbt seed จะได้ตาราง coffee_sales_scd_new และ province_region_mapping_v2 ส่วน staging models เป็น view สำหรับใช้งานต่อ

3. สร้าง Snowflake dimensions

สร้าง geography hierarchy: region → province → store

models/marts/dim_region.sql

```

{{ config(materialized='table') }}
select distinct
  md5(region_name) as region_key,
  region_name
from {{ ref('stg_province_region') }}

```

models/marts/dim_province.sql

```

{{ config(materialized='table') }}
select
  md5(p.province_name) as province_key,
  p.province_name,
  r.region_key
from {{ ref('stg_province_region') }} p
join {{ ref('dim_region') }} r on r.region_name=p.region_name

```

models/marts/dim_store.sql

```

{{ config(materialized='table') }}
select distinct
  md5(s.store_code) as store_key,
  s.store_code, s.store_name, p.province_key
from {{ ref('stg_coffee_sales') }} s
join {{ ref('dim_province') }} p on p.province_name=s.province

```

สร้าง product hierarchy: category → product และ staff hierarchy: position → staff

models/marts/dim_category.sql

```

{{ config(materialized='table') }}
select distinct md5(category) as category_key, category as category_name
from {{ ref('stg_coffee_sales') }}

```

models/marts/dim_product.sql

```

{{ config(materialized='table') }}
select distinct

```

```
md5(concat_ws('|',s.product_code,s.size)) as product_key,
s.product_code, s.product_name, c.category_key, s.size, s.unit_price
from {{ ref('stg_coffee_sales') }} s
join {{ ref('dim_category') }} c on c.category_name=s.category
```

models/marts/dim_position.sql

```
{{ config(materialized='table') }}
select distinct md5(position) as position_key, position
from {{ ref('stg_coffee_sales') }}
```

models/marts/dim_staff.sql

```
{{ config(materialized='table') }}
select distinct
md5(s.staff_code) as staff_key,
s.staff_code, s.staff_name, p.position_key
from {{ ref('stg_coffee_sales') }} s
join {{ ref('dim_position') }} p on p.position=s.position
```

models/marts/dim_promotion.sql

```
{{ config(materialized='table') }}
select distinct
md5(promo_code) as promo_key, promo_code, promo_desc
from {{ ref('stg_coffee_sales') }}
where promo_code is not null
```

models/marts/dim_date.sql

```
{{ config(materialized='table') }}
select distinct
to_char(sale_date,'YYYYMMDD')::int as date_key,
sale_date,
extract(year from sale_date)::int as year,
extract(month from sale_date)::int as month,
extract(quarter from sale_date)::int as quarter
from {{ ref('stg_coffee_sales') }}
```

```
dbt run --select dim_region dim_province dim_store dim_category dim_product dim_position dim_staff
dim_promotion dim_date
```

หมายเหตุ: ทุก dimension ใช้ md5() สร้าง surrogate key แบบ deterministic ดังนั้น rerun model แล้ว key ของ business key เดิมจะไม่เปลี่ยน

4. สร้าง SCD Type 2 ของลูกค้า

int_customer_source เลือกสถานะล่าสุดของลูกค้าใน batch ที่กำลังโหลด โดยใช้ source_change_date เป็นวันที่เริ่มมีผลของข้อมูลนั้น

models/intermediate/int_customer_source.sql

```
with batch as (
select *
from {{ ref('stg_coffee_sales') }}
{% if var('load_batch','initial') == 'initial' %}
where sale_date < date '2031-04-15'
{% else %}
where sale_date >= date '2031-04-15'
{% endif %}
), ranked as (
```

```

select
  customer_code, customer_name, gender, birth_year,
  sale_date as source_change_date,
  row_number() over (
    partition by customer_code, customer_name
    order by sale_date, sale_id
  ) as rn
from batch
)
select customer_code, customer_name, gender, birth_year, source_change_date
from ranked
where rn=1

```

snapshots/snap_customer_scd.sql

```

{% snapshot snap_customer_scd %}
{{
  config(
    unique_key='customer_code',
    strategy='check',
    check_cols=['customer_name','gender','birth_year'],
    invalidate_hard_deletes=False
  )
}}
select * from {{ ref('int_customer_source') }}
{% endsnapshot %}

```

สร้าง dim_customer โดยใช้ช่วงวันที่จาก source_change_date เพื่อให้ fact จับคู่กับ version ที่มีผลในวันขาย

models/marts/dim_customer.sql

```

{{ config(materialized='table') }}

with versioned as (
  select
    customer_code, customer_name, gender, birth_year,
    source_change_date::date as start_date,
    lead(source_change_date::date) over (
      partition by customer_code
      order by source_change_date::date
    ) as next_start_date,
    dbt_valid_to
  from {{ ref('snap_customer_scd') }}
)
select
  md5(concat_ws('|',customer_code,start_date::text)) as customer_key,
  customer_code, customer_name, gender, birth_year, start_date,
  coalesce(next_start_date - 1,date '9999-12-31') as end_date,
  (dbt_valid_to is null) as is_current
from versioned

```

5. สร้าง incremental fact model

models/intermediate/int_sales_batch.sql

```

select *
from {{ ref('stg_coffee_sales') }}
{% if var('load_batch','initial') == 'initial' %}
where sale_date < date '2031-04-15'
{% else %}
where sale_date >= date '2031-04-15'
{% endif %}

```

models/marts/fct_sales.sql

```

{{
  config(
    materialized='incremental',
    unique_key='sale_id',
    incremental_strategy='merge'
  )
}}
select
  s.sale_id, s.invoice_number, d.date_key, c.customer_key,
  p.product_key, st.store_key, sf.staff_key, pr.promo_key,
  s.quantity, s.revenue, s.points_redeemed
from {{ ref('int_sales_batch') }} s
join {{ ref('dim_date') }} d on d.sale_date=s.sale_date
join {{ ref('dim_customer') }} c
  on c.customer_code=s.customer_code
  and s.sale_date between c.start_date and c.end_date
join {{ ref('dim_product') }} p on p.product_code=s.product_code and p.size=s.size
join {{ ref('dim_store') }} st on st.store_code=s.store_code
join {{ ref('dim_staff') }} sf on sf.staff_code=s.staff_code
left join {{ ref('dim_promotion') }} pr on pr.promo_code=s.promo_code
{% if is_incremental() %}
where not exists (
  select 1 from {{ this }} f where f.sale_id=s.sale_id
)
{% endif %}

```

5.1 โหลด Batch 1

```

dbt run --select int_customer_source --vars '{"load_batch': 'initial'}"
dbt snapshot --select snap_customer_scd --vars '{"load_batch': 'initial'}"
dbt run --select dim_customer int_sales_batch fct_sales --vars '{"load_batch': 'initial'}"

```

5.2 โหลด Batch 2

```

dbt run --select int_customer_source --vars '{"load_batch': 'incremental'}"
dbt snapshot --select snap_customer_scd --vars '{"load_batch': 'incremental'}"
dbt run --select dim_customer int_sales_batch fct_sales --vars '{"load_batch': 'incremental'}"

```

รายการตรวจ	ผลที่คาดหวัง
หลัง Batch 1	fct_sales = 40 แถว
หลัง Batch 2	fct_sales = 80 แถว และ sale_id ไม่ซ้ำ
SCD Type 2	CUST-1007 มี 2 versions: Arthit (is_current=false) และ Tawon (is_current=true)

สิ่งที่ต้องส่ง

- Screenshot จำนวน fct_sales หลัง Batch 1 = 40 และหลัง Batch 2 = 80
- Screenshot SCD history ของ CUST-1007